

R-PL5

Gabriel López, Sergio Sanz, Álvaro Zamorano

3 de diciembre de 2019

1. Ejercicio realizado en clase.

1.1. K-vecinos

A partir del siguiente conjunto de calificaciones académicas, formados por dos notas: teoría y laboratorio, que tendrán valores entre 0 y 5, realizar un análisis de detección de datos anómalos utilizando el algoritmo **K-vecinos**.

| Alumno | Teoría | Laboratorio |
|--------|--------|-------------|
| A1 | 4 | 4 |
| A2 | 4 | 3 |
| A3 | 5 | 5 |
| A4 | 1 | 1 |
| A5 | 5 | 4 |

En primer lugar se introducirán los datos en forma de matriz y se hará la traspuesta de esta.

```
> muestra = matrix(c(4,4,4,3,5,5,1,1,5,4),2,5)
> muestra = t(muestra)
```

En segundo lugar, calculamos las distancias euclídeas entre todos los puntos y los almacenamos en una matriz. El cálculo de las distancias lo realizamos mediante la función **as.matrix**.

```
> distancias = as.matrix(dist(muestra))
> distancias = matrix(distancias,5,5)
```

En tercer lugar, ordenamos las columnas de la matriz de distancias por los valores de cada una de las filas de menor a mayor. Se tiene en cuenta el **tercer** vecino, por lo que debemos estudiar la cuarta fila de la matriz ya que se tiene en cuenta la distancia de un punto consigo mismo. Se obtienen las muestras cuyo suceso es anómalo o outlier, el grado de outlier es 2.5.

```
> source("./Funciones/anomalosKVecinos.R")
> anomalosKVecinos
```

```

function (distancias, muestra, k, grado,dimensiones) {
  tmp<-" "

  for(i in 1:(length(muestra)/dimensiones)){
    distancias[,i] = sort(distancias[,i])
    if(distancias[k+1,i] > grado) {
      valor<-" "
      for (j in 1:dimensiones){
        valor<-paste(valor,muestra[k+1,j])
      }
      tmp<-paste(tmp,"La muestra ", i,
        " con valor (", valor, ") es outlier - ",sep="")
    }
  }

  return(tmp)
}

```

Procedemos a su ejecución:

```

> (anomalosKVecinos(distancias,muestra,3,2.5,2))

[1] "La muestra 4 con valor ( 1 1) es outlier - "

```

Es importante indicar que la función necesita conocer el número de **dimensiones** que tiene la muestra.

1.2. Caja y bigotes.

A partir del siguiente conjunto de valores de resistencia y densidad para diferentes tipos de hormigón, se hará un análisis para la detección de outliers utilizando medidas de ordenación sobre la resistencia con el método de **Caja y Bigotes**.

| Hormigón | Resistencia | Densidad |
|----------|-------------|----------|
| H1 | 3 | 2 |
| H2 | 3.5 | 12 |
| H3 | 4.7 | 4.1 |
| H4 | 5.2 | 4.9 |
| H5 | 7.1 | 6.1 |
| H6 | 6.2 | 5.2 |
| H7 | 14 | 5.3 |

En primer lugar, introducimos los datos en una matriz y lo convertimos a dataframe para que el trabajo con las columnas sea más cómodo.

```
> muestra = t(matrix(c(3,2,3.5,12,4.7,4.1,5.2,4.9,7.1,6.1,6.2,5.2,14,5.3),
+      2,7,dimnames = list(c("r","d"))))
> muestra = data.frame(muestra)
```

En segundo lugar:

1. Se determina el grado de outlier de forma arbitraria. El valor dado es 1.5.
2. Se ordenan los datos y se obtienen los cuartiles.

```
> cuar1 <- quantile(muestra$r,0.25)
> cuar3 <- quantile(muestra$r,0.75)
```

3. Se calculan los límites del intervalo.

```
> int = c(cuar1 - 1.5 * (cuar3 - cuar1), cuar3 + 1.5*(cuar3-cuar1))
```


4. Se identifican como outliers los valores que quedan fuera del intervalo.

```
> for(i in 1:length(muestra$r)){
+   if(muestra$r[i] < int[1] || muestra$r[i] > int[2]){
+     print("El suceso "); print(i);print(" con valor ");
+     print(muestra$r[i]); print(" es un suceso anomalo o outlier")
+   }
+ }
```

```
[1] "El suceso "
[1] 7
[1] " con valor "
[1] 14
[1] " es un suceso anomalo o outlier"
```

Por último, mostramos el diagrama de caja y bigotes donde se identifica el valor anómalo.

```
> source("./Funciones/Bigotes.R")
> bigotes(muestra$r,"bigotes.png",1.5)
```



1.3. Desviación Típica.

Ahora con los mismos datos del apartado anterior deseamos realizar un análisis de detección de datos anómalos utilizando medidas de dispersión sobre la densidad con el método de **Desviación Típica**.

1. Se determina el grado de outlier de forma arbitraria. El valor dado es 2.

2. Se obtiene la media aritmética.

```
> media<-mean(muestra$d)
```

3. Se obtiene la desviación típica.

```
> sdd<-sd(muestra$d)
```

```
> desviacion<-sqrt((sdd^2)*((length(muestra$d)-1)/length(muestra$d)))
```

4. Y por último, se calculan los límites del intervalo para los valores atípicos.

```
> intdes<-c(media-2*desviacion,media+2*desviacion)
```

5. Se identifican como outliers los valores que quedan fuera del intervalo.

```

> for(i in 1:length(muestra$d)){
+   if(muestra$d[i] < intdes[1] || muestra$d[i] > intdes[2]){
+     print("El suceso "); print(i);print(" con valor ");
+     print(muestra$d[i]); print(" es un suceso anomalo o outlier")
+   }
+ }

[1] "El suceso "
[1] 2
[1] " con valor "
[1] 12
[1] " es un suceso anomalo o outlier"

```